






MLOPS PODRŠKA ZA SISTEM VIZUELNOG PREPOZNAVANJA GOVORA ZASNOVAN NA LIPCOORDNET MODELU

**PREDMET:
TEHNOLOGIJE I ALATI U MAŠINSKOM UČENJU**

**STUDENT:
TIJANA KLJAJIĆ**



ODABRANE MLOPS KOMPONENTE

1

PRIMENA I
SERVIRANJE

2

MONITORING

3

ODRŽAVANJE

OD TEORIJE DO IMPLEMENTACIJE

Komponenta	Aktuelna produkciona praksa	Projekat
Serviranje	Versioned API / inference server, model registry, batching, autoscaling, health/readiness	FastAPI servis, 4 endpoint-a, CPU Docker image
Monitoring	Metrics, logs, traces, alerting, drift monitoring	CSV logovi, /stats, latencija, HTTP greške, WER, confidence
Održavanje	CI/CD/CT, registry, lineage, approval, rollback, scheduled checks	20 testova, WER quality gate, Docker, GitHub Actions, Metaflow

CILJ PROJEKTA

PRETRAINED LIPCOORD NET

Video sekvence usana →
tekstualna transkripcija



PROBLEM



Kako model učiniti dostupnim,
merljivim i reproduktivnim?



CILJ PROJEKTA


Izgraditi operativni MLOPs sloj
oko postojećeg modela

LIPCOORDNET MODEL





MLOPS SLOJ



Serviranje

01

FastAPI
Model je dostupan kroz API
endpoint-e.

Monitoring

02

Vreme obrade i HTTP greške
Pratimo ponašanje servisa tokom
rada.

Kontrola kvaliteta

03

Testovi, WER i confidence score
Proveravamo rezultate i prag
kvaliteta.

Reproduktivnost

04

Docker
Isto okruženje pri pokretanju na
drugom računaru.

Automatizacija provera

05

Metaflow i GitHub Actions
Validacija, testovi, evaluacija i
build.



FASTAPI SERVIS



Model je dostupan kroz jednostavne HTTP endpoint-e

GET /predict/0

Zahtev za demo uzorak

FastAPI servis

Prima zahtev i poziva model

LipCoordNet model

Vraća tekstualnu predikciju

Indeks uzorka može biti 0, 1 ili 2, u zavisnosti od demo skupa.

LipCoordNet API 0.1.0 OAS 3.1

/openapi.json

default


GET /health Health

GET /predict/{sample_index} Predict Sample

GET /stats Stats

MONITORING I METRIKE

Praćenje ponašanja servisa i kvaliteta predikcija



LATENCIJA

Vreme obrade zahteva

- Da li servis odgovara dovoljno brzo?



HTTP GREŠKE

Status i greške API-ja

- Da li je zahtev uspešno obrađen?



WER (↓)

Word Error Rate

- Koliko se predikcija razlikuje od reference?




CONFIDENCE SCORE (↑)

Procena sigurnosti modela

- Koliko je model siguran u rezultat?



TESTIRANJE I EVALUACIJA



AUTOMATSKI TESTOVI

20 / 20

Endpointi, očekivani
odgovori i obrada
grešaka

EVALUACIJA MODELA

WER = 5,56%

Poređenje predikcije sa
referentnim tekstom


QUALITY GATE

WER $\leq$ 10%

Ako je prag ispunjen,
evaluacija prolazi



DOCKER



DOCKER IMAGE

Spakovano okruženje

Ista verzija aplikacije i zavisnosti

`lipcoordnet-api:1.1`



CONTAINER

Pokrenut FastAPI servis

Servis dostupan na mapiranom portu

`8001 → 8000`

POKRETANJE NA DRUGOM RAČUNARU


```
docker build -t lipcoordnet-api:1.1 .
```

```
docker run --rm -p 8001:8000 lipcoordnet-api:1.1
```

Swagger dokumentacija

`127.0.0.1:8001/docs`

METAFLOW PIPELINE



ZAŠTO METAFLOW?

Koraci su jasno organizovani, ponovljivi i lakši za praćenje.


REPRODUKTIVNA EVALUACIJA

Isti checkpoint i isti koraci daju uporediv rezultat.




GITHUB ACTIONS

Automatska provera svake izmene



OKIDAČ

Push ili pull request
Ručno pokretanje
Nedeljni raspored



WORKFLOW

Čisto Python okruženje
Instalacija zavisnosti




PROVERE

20 testova
Metaflow evaluacija
 $WER \leq 10\%$



REZULTAT

PASS - sve provere
uspešne
FAIL - neka provera nije
prošla
Docker build je uspešan



**HVALA NA
PAŽNJI**

